Administración de Bases de Datos

Proyecto Final: Potencial Solar de Techos en Municipios PDET



Estudiantes:

Samuel Tovar
Juan Romero
Carlos Pinzón Caicedo
Alejandro Padilla Gaviria

Entrega 2:

Fronteras PDET (DANE MGN 2025) e Integración Espacial en MongoDB

Pontificia Universidad Javeriana

9 de noviembre de 2026

Índice

1. Introducción **2**
1.1. Flujo de la entrega 2

2. Adquisición y Verificación de los Datos **3**
2.1. Fuentes y mecanismo de descarga 3
2.2. Verificación de integridad 3
2.3. Filtro PDET y controles de calidad 3

3. Integridad Geométrica y Formateo del ETL **4**
3.1. Normalización espacial y reparación topológica 4
3.2. Salida estandarizada e ingesta idempotente 5

4. Integración Espacial en MongoDB **5**
4.1. Carga e índices 5
4.2. Evidencia del uso de los índices 5

5. Conclusiones y Siguientes Pasos **6**

Índice de figuras

1. Flujo de la Entrega 2: de la descarga del MGN2025 a la evidencia de los índices en MongoDB. 2

Índice de tablas

1. Criterios de evaluación de la Entrega 2 y su ubicación en el informe y en el repositorio. 2
2. Controles de calidad sobre el MGN2025 filtrado a los municipios PDET (31 OK, 1 AVISO, 0 FALLA). 4
3. Planes de ejecución de las consultas espaciales sobre `municipalities`. 6

1. Introducción

Esta entrega integra al proyecto los límites de los 170 municipios PDET, tomados de la capa municipal del Marco Geoestadístico Nacional 2025 del DANE, y los deja cargados en MongoDB con índices espaciales. Es la base sobre la que, en las entregas siguientes, se asignarán las huellas de edificios a cada municipio y se calcularán el número de techos y su área. El enunciado evalúa tres aspectos, que el Cuadro 1 relaciona con las secciones del informe y con los archivos del repositorio (https://github.com/SamT81/Proyecto-ABD).

Criterio del enunciado	**Sección**	**Archivos principales**	**Rama**
Adquisición y verificación de los datos	2	`00a_download_mgn.py`, `00b_build_pdet_catalog.py`, `00c_filter_pdet.py`, `docs/calidad/`	`feat/pdet-acquisition`
Integridad y formato para la ingesta	3	`01_load_municipalities.py`, `utils/geo_integrity.py`	`feat/pdet-integrity-etl`
Integración espacial NoSQL (índices)	4	`load_to_mongo.py`, `pdet_mongo.py`, `spatial_evidence.py`	`feat/spatial-mongo`

Tabla 1: Criterios de evaluación de la Entrega 2 y su ubicación en el informe y en el repositorio.

1.1. Flujo de la entrega

La Figura 1 muestra el recorrido de los datos. Cada etapa verifica su entrada y se detiene con un error si un control falla, de modo que no llegan datos dudosos a la etapa siguiente.

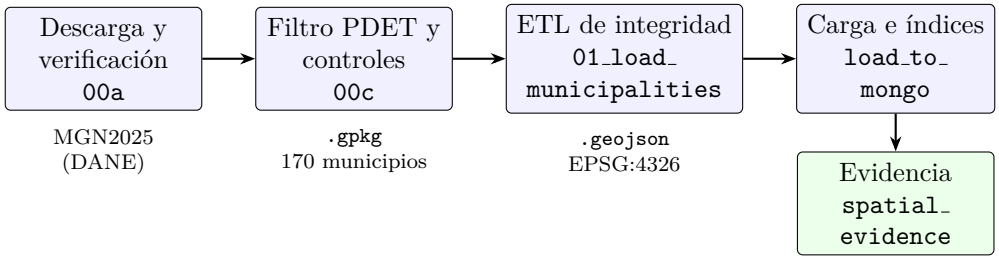


Figura 1: Flujo de la Entrega 2: de la descarga del MGN2025 a la evidencia de los índices en MongoDB.

2. Adquisición y Verificación de los Datos

2.1. Fuentes y mecanismo de descarga

Los límites municipales se toman del Marco Geoestadístico Nacional 2025 del DANE. En el plan de la Entrega 1 se previó descargar el ZIP completo (1.5 GB, todos los niveles geográficos), pero el geoportal publica el nivel municipio por separado (`MGN2025_MPIO_GRAFICO.zip`, 71.6 MB, Shapefile en WGS84) con la misma versión y la misma capa, por lo que se descarga solo ese archivo. El listado de los 170 municipios PDET y su subregión se toma de la Agencia de Renovación del Territorio (Decreto 893 de 2017).

La descarga la hace `src/00a_download_mgn.py`: lee el archivo por bloques de 1 MB a un temporal `.part`, reintenta y reanuda con cabecera `Range` si la conexión se corta, y solo renombra el archivo cuando su tamaño coincide con el `Content-Length` del servidor. La URL, las rutas y los valores de referencia están en `config/acquisition.yaml`, no en el código.

```
python src/00a_download_mgn.py      # descarga y verifica (si ya existe, solo
    verifica)
python src/00c_filter_pdet.py       # filtro PDET y controles -> data/
    mgn_pdet_2025.gpkg
python src/01_load_municipalities.py
```

2.2. Verificación de integridad

El DANE no publica un *checksum* oficial. Por eso, en la primera descarga (08/11/2026) se fijó en la configuración el SHA-256 del ZIP (`a3c01393...bc141f`), su tamaño (71 576 494 bytes) y las cabeceras `Last-Modified` y `ETag`. Cada corrida recalcula el SHA-256 y falla si no coincide, lo que garantiza que todo el equipo procese exactamente los mismos bytes y detecta si el DANE reemplaza el archivo. Además se valida el CRC de los ocho archivos del ZIP y la presencia de los componentes del Shapefile (`.shp`, `.shx`, `.dbf`, `.prj`, `.cpg`). El SHA-256 de cada archivo extraído queda en `docs/calidad/manifest_mgn.json` y se vuelve a comprobar antes del filtrado.

2.3. Filtro PDET y controles de calidad

`src/00c_filter_pdet.py` cruza la capa municipal (1 122 unidades) con el listado PDET por código DIVIPOLA. En el Excel de la ART los códigos de Antioquia aparecen sin el cero inicial (`5490` en lugar de `05490`), así que se normalizan a cinco dígitos antes del cruce. El Cuadro 2 resume los 32 controles; el detalle está en `docs/calidad/qc_mgn_pdet.md`.

Grupo	Controles	Resultado
Fuente	SHA-256 del ZIP verificado; archivos extraídos sin cambios	2 OK
Capa MGN	Campos requeridos; CRS EPSG:4326; 1 122 unidades; código único, de 5 dígitos y coherente con el departamento; sin nulos; extensión dentro de Colombia	8 OK
Listado PDET	170 municipios; códigos únicos y de 5 dígitos; 16 subregiones; prefijo coherente; sin nulos	6 OK
Cruce	170/170 códigos encontrados; departamento coincide; nombre coincide	2 OK, 1 AVISO
Geometría	170 polígonos únicos, no vacíos y válidos; área EPSG:9377 vs. `mpio_narea` (diferencia 0.000 %); sin solapes (339 pares vecinos); geometría más pesada 2.2 MB (límite BSON 16 MB)	10 OK
Salida	GeoPackage releído: 170 registros, EPSG:4326, sin nulos	3 OK

Tabla 2: Controles de calidad sobre el MGN2025 filtrado a los municipios PDET (31 OK, 1 AVISO, 0 FALLA).

El único aviso corresponde a seis municipios cuyo nombre en el listado de la ART difiere del nombre oficial del MGN2025. Como el cruce es por código, no afecta el resultado; se conserva el nombre del MGN. Los 170 municipios suman 389 182 km^2 en 16 subregiones. La salida, `data/mgn_pdet_2025.gpkg` (EPSG:4326, geometrías `MultiPolygon`), es la entrada del ETL de integridad.

3. Integridad Geométrica y Formateo del ETL

3.1. Normalización espacial y reparación topológica

Una vez filtrada la capa municipal a los 170 municipios PDET (`data/mgn_pdet_2025.gpkg`), el módulo `src/utils/geo_integrity.py` y el orquestador `src/01_load_municipalities.py` aseguran que cada registro cumpla los requisitos estrictos del índice `2dsphere` de MongoDB y del diccionario de datos definido en la Entrega 1:

- **Reparación topológica y tipo uniforme:** toda geometría se valida y repara con `shapely.validation.make_valid`, descartando componentes degenerados y promoviendo polígonos simples a `MultiPolygon`. Asimismo, se orientan los anillos exteriores en sentido antihorario y los huecos en sentido horario (regla de la mano derecha) para evitar errores de indexación en coordenadas esféricas.
- **Doble sistema de referencia:** el área oficial en kilómetros cuadrados (`area_km2`) se calcula proyectando temporalmente a **EPSG:9377** (MAGNA-SIRGAS Origen Nacional) antes de transformar definitivamente las geometrías a **EPSG:4326** (WGS84), redondeando coordenadas a 7 decimales ($\approx$ 1,1 cm de precisión) para reducir el tamaño BSON sin pérdida geométrica apreciable y evitando auto-intersecciones de anillos.

- **Validación de dominio y tamaño BSON:** se verifica que los 170 códigos DIVIPOLA tengan 5 dígitos únicos, sin campos obligatorios nulos, que sus envolventes caigan dentro de la caja geográfica de Colombia ($[-82°, -5°, -66°, 14°]$) y que ningún documento supere el umbral preventivo de 15.5 MB frente al límite de 16 MB de MongoDB.

3.2. Salida estandarizada e ingesta idempotente

El script `src/01_load_municipalities.py` genera el archivo limpio `data/processed/pdet_municipios` (consumido por la integración espacial), guarda la bitácora de validación en `docs/calidad/etl_integrity_` y permite la carga directa e idempotente en `municipalities` mediante operaciones `ReplaceOne(..., upsert=True)` indexadas por `_id` (DIVIPOLA).

El ETL se validó con los datos reales del MGN2025: leyó 170 municipios, los 170 resultaron válidos (0 rechazados, 0 geometrías descartadas), en 16 subregiones y con un área total de 389 182.04 km^2 calculada en EPSG:9377. El documento más grande pesa unos 1.24 MB, muy por debajo del límite BSON de 16 MB. Su bitácora queda en `docs/calidad/etl_integrity_report.json`, con el SHA-256 del archivo de entrada y del GeoJSON de salida.

4. Integración Espacial en MongoDB

4.1. Carga e índices

Los municipios PDET limpios (GeoJSON en EPSG:4326, producido por el ETL de integridad) se cargan en la colección `municipalities` con `src/load_to_mongo.py`. La carga es idempotente (*upsert* por `_id`, el código DIVIPOLA), las geometrías se normalizan a `MultiPolygon` con la regla de la mano derecha y se rechazan las inválidas o ubicadas fuera de la caja de Colombia. Los índices se crean antes de insertar, de modo que MongoDB también rechaza cualquier geometría que no pueda indexar.

```
db.municipalities.createIndex({ geometry: "2dsphere" }, { name: "
    geometry_2dsphere" })
db.municipalities.createIndex({ pdet_subregion: 1 },    { name: "
    pdet_subregion_1" })
```

La carga queda registrada en `ingestion_log` (archivo, filas leídas, insertadas y rechazadas, SHA-256 del archivo y fecha). Resultado: 170 municipios cargados de 170 esperados, 16 subregiones, 0 rechazados.

4.2. Evidencia del uso de los índices

Se ejecutaron consultas `$geoIntersects`, `$geoWithin` y `$near` con `explain(.ªecutionStats")`, comparando el plan con el índice `2dsphere` frente a un recorrido completo forzado con `hint({$natural: 1})`. El Cuadro 3 resume los planes ganadores y los documentos examinados.

Consulta	Plan ganador	Docs (índice)	Docs (sin índice)	Devueltos
punto_en_pol	FETCH/IXSCAN	1	170	1
punto_en_pol	FETCH/IXSCAN	1	170	1
punto_en_pol	FETCH/IXSCAN	2	170	1
punto_en_pol	FETCH/IXSCAN	1	170	1
punto_en_pol	FETCH/IXSCAN	1	170	1
punto_en_el_	FETCH/IXSCAN	0	170	0
ventana_geoW	FETCH/IXSCAN	34	170	18
vecinos_geol	FETCH/IXSCAN	5	170	1
cercanos_nea	GEO_NEAR_2DSPHERE...	335	–	18

Tabla 3: Planes de ejecución de las consultas espaciales sobre `municipalities`.

Los controles automáticos (índice presente, número de municipios y subregiones, códigos DIVIPOLA de cinco dígitos, tipo `MultiPolygon`, y consultas punto-en-polígono cuyo resultado se verifica contra el municipio de origen) se reportan en `docs/evidencia/spatial_evidence.md`. Con 170 documentos la diferencia de tiempo es pequeña, pero el plan cambia de `COLLSCAN` a `IXSCAN`; la ventaja crecerá exponencialmente en las colecciones de edificios (Entrega 3), con millones de documentos.

5. Conclusiones y Siguientes Pasos

- Los límites de los 170 municipios PDET provienen del MGN2025 con una descarga reproducible y verificada por SHA-256, y pasaron 31 controles de calidad sin fallas (un aviso por diferencias de nombre con el listado de la ART, que no afecta el cruce por código DIVIPOLA).
- El ETL entrega geometrías válidas, orientadas, en EPSG:4326, con el área calculada en EPSG:9377, lista para el índice `2dsphere`; no fue necesario simplificar ni partir ningún municipio tras ajustar a 7 decimales.
- La integración espacial crea los índices antes de la carga, registra cada ingesta en `ingestion_log` y automatiza la evidencia con `explain()` para comparar el plan con índice frente al recorrido completo.
- **Limitación:** el tamaño de esta colección (170 documentos) hace que las diferencias de tiempo entre `IXSCAN` y `COLLSCAN` sean pequeñas; el beneficio del índice se medirá con las colecciones de edificios de la Entrega 3.
- **Siguientes pasos:** cargar las huellas de Microsoft y Google por lotes, asignar a cada edificio su `municipality_code` con el punto representativo, y hacer el análisis exploratorio (Entrega 3).