Administración de Bases de Datos
Proyecto Final: Potencial Solar de Techos en Municipios PDET
Entrega 1: Diseño del Esquema NoSQL y Plan de Implementación

Samuel Tovar Juan Romero
Pontificia Universidad Javeriana

2 de noviembre de 2026

1. Introducción

Este informe presenta la primera entrega del proyecto final de Administración de Bases de Datos: el diseño del esquema NoSQL y el plan de implementación para estimar el potencial solar de los techos en los municipios PDET (Programas de Desarrollo con Enfoque Territorial), tal como lo solicita la Oficina de Investigación e Información de la Unidad de Planeación Minero Energética (UPME). Su objetivo es fijar la tecnología, las fuentes de datos, el modelo de datos (diagrama E-R y diccionario) y el plan de trabajo de las entregas 2 a 5.

La UPME busca identificar municipios donde desplegar pruebas de concepto de energía solar. El criterio de priorización son los territorios PDET (170 municipios agrupados en 16 subregiones): a mayor área de techos aprovechables, mayor potencial de captación solar. El proyecto debe contar las edificaciones y estimar el área total de techos aptos por municipio PDET, con una solución NoSQL y comparando al menos dos conjuntos de datos abiertos de huellas de edificios.

Los archivos del proyecto (este PDF, su fuente en LaTeX, el diagrama E-R, el archivo `docker-compose.yml` y los parámetros) se entregan en el repositorio https://github.com/SamT81/Proyecto-ABD.

2. Selección y Descripción de las Fuentes de Datos

- **Microsoft Building Footprints** (seleccionada). Huellas de edificios derivadas de imágenes de Bing Maps (2014–2021, con fuentes como Maxar y Airbus), con más de 999 millones de detecciones en el mundo. Licencia ODbL. Fuente: https://planetarycomputer.microsoft.com/dataset/ms-buildings. Aporta la geometría del edificio; el área se calcula en el ETL.

- **Google Open Buildings** (seleccionada). 1800 millones de detecciones en 58 millones de km^2 (África, Asia del Sur y del Sudeste, América Latina y el Caribe), en su tercera versión. Licencias CC BY 4.0 y ODbL v1.0. Fuente: https://sites.research.google/gr/open-buildings/. Incluye el área (`area_in_meters`) y un puntaje de confianza por edificio.

- **GlobalBuildingAtlas, TUM** (no seleccionada). 2750 millones de modelos de edificios a partir de imágenes de 2019, con resolución de 3×3 m y modelos 3D. Licencia MIT con *Commons Clause*. Fuente: https://github.com/zhu-xlab/GlobalBuildingAtlas. Excede el mínimo de dos fuentes y su valor agregado (altura 3D) no es necesario para estimar el área de techo; queda como extensión opcional.

- **DANE, Marco Geoestadístico Nacional (MGN) 2025.** Límites administrativos de Colombia en todos los niveles geográficos (ZIP de 1.5 GB). Se extrae la capa municipal. Fuente: https://geoportal.dane.gov.co/.

- **Lista de municipios PDET.** 170 municipios en 16 subregiones, según la Agencia de Renovación del Territorio (Decreto 893 de 2017). Se usa para filtrar la capa municipal del MGN por código DIVIPOLA de 5 dígitos.

3. Metodología

3.1. Herramientas

- **MongoDB** (Community Server, en Docker): almacén de documentos con soporte nativo de GeoJSON, índices `2dsphere`, operadores `$geoWithin` y `$geoIntersects` y *aggregation pipeline*.
- **Python** con `geopandas`, `pyarrow` y `pymongo` para el ETL: lectura por partes, reparación de geometrías, reproyección y carga.
- **Docker Compose** para levantar la base de datos de forma reproducible.
- **QGIS** o **MongoDB Compass** para validar visualmente geometrías e índices.

3.2. Decisiones clave

El Cuadro 1 resume las decisiones de diseño y su justificación.

Decisión	Elección	Justificación
Motor NoSQL	**MongoDB** (almacén de documentos, Community Server en Docker)	Soporte nativo de GeoJSON, índices `2dsphere`, operadores `$geoWithin` / `$geoIntersects` y *aggregation pipeline* para agrupar por municipio. Cliente Python (`pymongo`) maduro y esquema flexible para atributos distintos por fuente.
Datasets (mínimo 2)	**Microsoft Building Footprints** y **Google Open Buildings**	Ambos cubren Colombia. Google incluye área y confianza; Microsoft aporta la geometría y el área se calcula, lo que hace interesante la comparación. Formatos distintos (GeoParquet/GeoJSON frente a CSV) exigen un ETL robusto.
Fronteras	**DANE MGN 2025**, nivel municipal, filtrado a los 170 municipios PDET	Fuente oficial. La lista PDET se toma de la Agencia de Renovación del Territorio (Decreto 893 de 2017) y se cruza por código DIVIPOLA de 5 dígitos.
Sistema de coordenadas	Almacenamiento en **EPSG:4326**; áreas en **EPSG:9377**	`2dsphere` requiere longitud/latitud en WGS84. Calcular áreas en grados no es válido; MAGNA-SIRGAS Origen Nacional (EPSG:9377) es el CRS proyectado oficial para Colombia.
Edificio → municipio	`municipality_code` **pre-asignado en el ETL** con el punto representativo del edificio	Evita doble conteo en los límites y permite agregar con un índice simple, sin join espacial en cada consulta. `$geoWithin` se usa para validación cruzada.
Techo "apto"	Criterio **parametrizable**: `area_m2` $\geq A_{\min}$ y, en Google, `confidence` $\geq C_{\min}$	Valores iniciales a calibrar en el EDA (por ejemplo $A_{\min} = 15$ m^2, $C_{\min} = 0.70$). Se guardan en `results.params` para que cada resultado sea trazable.

Cuadro 1: Decisiones clave de diseño y su justificación.

3.3. Pasos

1. **Validar y reparar:** las geometrías se reparan con `make_valid`; las irrecuperables se descartan y se cuentan en `ingestion_log`.

2. **Calcular el área** en EPSG:9377: Microsoft se calcula; en Google se conserva `area_in_meters` original y se contrasta con el área recalculada en una muestra para verificar consistencia.

3. **Asignar municipio** con un join espacial entre el punto representativo del edificio y los polígonos PDET; los edificios fuera de PDET se descartan antes de insertar.

4. **Agregar** por (`municipality_code`, `source`): total de edificios, área total y área apta según los parámetros; el resultado se guarda en `results` junto con `params` y `computed_at`.

5. **Comparar fuentes:** diferencia absoluta y relativa de conteo y área por municipio, correlación y municipios con mayores discrepancias; ranking de municipios por área apta.

6. **Visualizar:** mapas coropléticos y tablas de los primeros N municipios.

3.4. Flujo general

```
[DANE MGN 2025] ----+
[Lista PDET (ART)] -+---> ETL Python (geopandas) --> municipalities  (2dsphere)

[Microsoft GeoParquet/GeoJSON] --> ETL por lotes --> buildings_microsoft (2dsphere)
[Google CSV.gz (celdas S2)]    --> ETL por lotes --> buildings_google    (2dsphere)
                                        |
                                        v
              Aggregation pipeline ($group por municipality_code)
                                        |
                                        v
              results --> tablas y mapas (geopandas, matplotlib) --> informe final
```

3.5. Fases y entregables

El Cuadro 2 asocia cada semana con su entrega y su producto.

Semana	Entrega	Actividades principales	Producto
1	Esquema NoSQL y plan	Selección de tecnología y datasets; diseño E-R; diccionario de datos; plan; repositorio base (README, `docker-compose`).	Este documento y repositorio inicial
2	Fronteras PDET	Descarga del MGN2025 (ZIP de 1.5 GB) y verificación (*checksum*, CRS, conteo = 170 municipios); filtrado PDET; reparación de geometrías; carga en `municipalities`; índice `2dsphere`.	Colección `municipalities`, bitácora de calidad
3	Huellas de edificios	Descarga solo de las particiones que intersectan PDET; carga por lotes con pre-asignación de municipio; índices; EDA (conteos, distribución de áreas, confianza, geometrías inválidas).	`buildings_microsoft`, `buildings_google`, EDA
4	Análisis y reporte final	Agregación por municipio y fuente; comparación entre fuentes; tablas y mapas coropléticos; informe técnico con discusión y recomendaciones; defensa.	`results`, mapas, informe final

Cuadro 2: Fases del proyecto y entregables asociados.

3.6. Manejo de grandes volúmenes

- **Filtrar en origen:** descargar solo archivos o celdas que intersecten la caja envolvente de los municipios PDET.

- **Lectura por partes** (*chunks* o *row groups* de Parquet); nunca cargar un archivo completo en memoria.
- **Inserción masiva:** `insert_many(ordered=False)` en lotes de 10 000 a 50 000 documentos y procesamiento en paralelo por archivo.
- **Índices después de la carga:** crear `2dsphere` y los demás índices al terminar la inserción, que es más rápido que mantenerlos durante la carga.
- **Carga idempotente y reanudable:** `ingestion_log` guarda *checksum* y conteos por archivo, de modo que un archivo ya cargado no se duplica.
- **Menos bytes por documento:** solo los campos necesarios y coordenadas con 6 decimales (≈0.1 m).

3.7. Reproducibilidad

```
repo/
  README.md              # pasos de ejecución de punta a punta
  docker-compose.yml     # MongoDB (y mongo-express opcional)
  requirements.txt       # dependencias con versiones fijas
  config/params.yaml     # rutas, CRS, A_min, C_min, tamaño de lote
  src/
    01_load_municipalities.py
    02_load_buildings.py
    03_compute_results.py
    04_make_maps.py
  docs/                  # PDFs de cada entrega, fuente del E-R (.dot) e imagen
  data/                  # ignorado por git; se documentan URLs y checksums
  notebooks/             # EDA
```

- Scripts numerados e idempotentes; un solo comando levanta la base de datos con Docker.
- Los datos no se versionan: el README documenta URL de descarga, fecha y *checksum* de cada fuente.
- Se respeta la atribución exigida por las licencias (ODbL y CC BY 4.0) en mapas e informe.

4. Diseño del Esquema y Modelado de Datos

4.1. Diagrama E-R

La Figura 1 muestra el diagrama E-R de las cinco colecciones.

4.2. Principios de diseño

- **Referenciar, no embeber:** un municipio tiene desde miles hasta cientos de miles de edificios; embeberlos superaría el límite de 16 MB por documento y haría ineficientes las actualizaciones.
- **Una colección por fuente:** los atributos y la calidad son distintos (`confidence` solo existe en Google). Así se comparan las fuentes y se recarga una sin afectar la otra.
- **Desnormalizar `municipality_code` en cada edificio:** cuesta pocos bytes por documento y evita un join espacial en cada agregación.
- **Resultados materializados:** `results` guarda cada cálculo con sus parámetros y fecha, lo que facilita mapas, tablas y la auditoría.

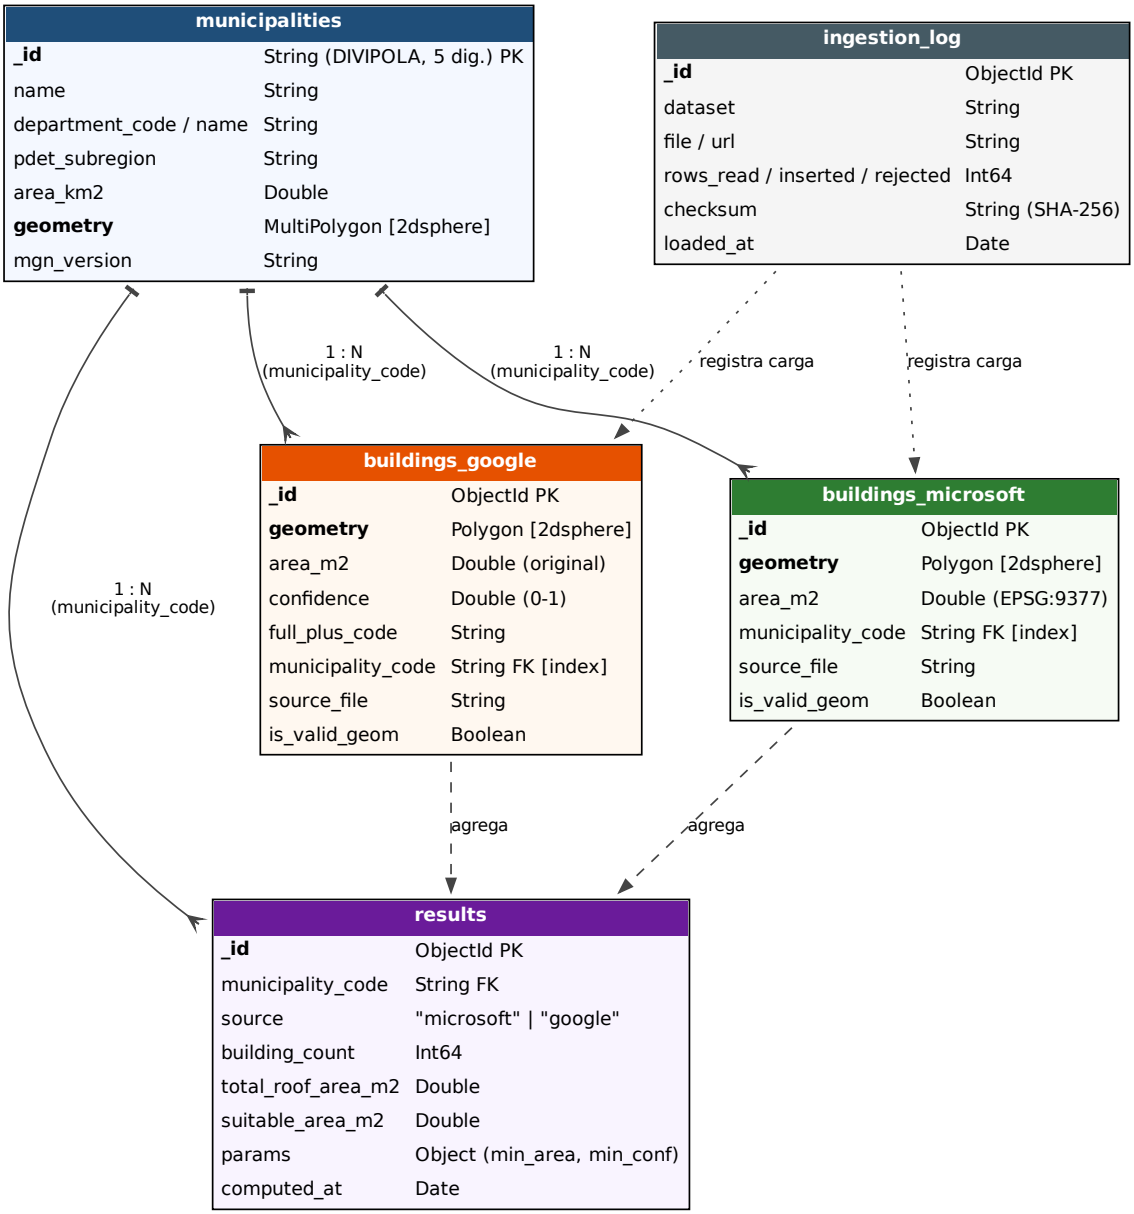


Figura 1: Diagrama E-R de las colecciones (PK: clave primaria, FK: clave lógica, [2dsphere] y [index]: índices). Cardinalidad 1:N en notación de pata de gallo.

- **Claves lógicas:** MongoDB no impone claves foráneas; `municipality_code` referencia a `municipalities._id` por convención y se valida en el ETL.

4.3. Diccionario de datos

Los Cuadros 3 a 7 describen los campos de cada colección. Los nombres exactos de los campos del MGN (códigos y nombres) se confirman en la Entrega 2 sobre la capa descargada.

Campo	Tipo	Req.	Descripción
`_id`	String	Sí	Código DIVIPOLA de 5 dígitos (2 de departamento + 3 de municipio), p. ej. "05045".
`name`	String	Sí	Nombre del municipio (campo de nombre de la capa MGN).
`department_code`	String	Sí	Código de departamento, 2 dígitos.
`department_name`	String	Sí	Nombre del departamento.
`pdet_subregion`	String	Sí	Subregión PDET (una de 16), según la lista de la ART.
`area_km2`	Double	Sí	Área calculada en EPSG:9377.
`geometry`	GeoJSON MultiPolygon	Sí	Límite municipal en WGS84. Índice `2dsphere`.
`mgn_version`	String	Sí	Versión del MGN usada (p. ej. "MGN2025").

Cuadro 3: Diccionario de datos de la colección `municipalities` (límites municipales PDET, DANE MGN).

Campo	Tipo	Req.	Descripción
`_id`	ObjectId	Sí	Identificador del documento.
`geometry`	GeoJSON Polygon	Sí	Huella del edificio en WGS84. Índice `2dsphere`.
`area_m2`	Double	Sí	Área calculada en EPSG:9377.
`municipality_code`	String (FK)	Sí	Referencia a `municipalities._id`. Indexado.
`source_file`	String	Sí	Archivo o partición de origen (trazabilidad).
`is_valid_geom`	Boolean	Sí	`false` si la geometría original era inválida y se reparó.

Cuadro 4: Diccionario de datos de la colección `buildings_microsoft` (huellas de Microsoft dentro de PDET).

4.4. Índices

El Cuadro 8 lista los índices por colección y el siguiente listado muestra cómo crear los principales.

```
db.municipalities.createIndex({ geometry: "2dsphere" })
db.buildings_google.createIndex({ geometry: "2dsphere" })
db.buildings_google.createIndex({ municipality_code: 1, area_m2: 1 })
```

5. Análisis: Ejemplos de Documentos y Consultas

5.1. Ejemplos de documentos

Los siguientes documentos son ilustrativos (los valores no provienen de los datos reales).

Campo	Tipo	Req.	Descripción
`_id`	ObjectId	Sí	Identificador del documento.
`geometry`	GeoJSON Polygon	Sí	Huella en WGS84 (convertida desde WKT). Índice `2dsphere`.
`area_m2`	Double	Sí	Área original de la fuente (`area_in_meters`).
`confidence`	Double	Sí	Puntaje de confianza del modelo (0 a 1).
`full_plus_code`	String	No	Plus Code de la fuente.
`municipality_code`	String (FK)	Sí	Referencia a `municipalities._id`. Indexado.
`source_file`	String	Sí	Archivo o celda S2 de origen.
`is_valid_geom`	Boolean	Sí	`false` si la geometría original era inválida y se reparó.

Cuadro 5: Diccionario de datos de la colección `buildings_google` (huellas de Google Open Buildings dentro de PDET).

Campo	Tipo	Req.	Descripción
`_id`	ObjectId	Sí	Identificador del documento.
`municipality_code`	String (FK)	Sí	Referencia a `municipalities._id`.
`source`	String	Sí	"microsoft" o "google".
`building_count`	Int64	Sí	Total de edificios detectados en el municipio.
`total_roof_area_m2`	Double	Sí	Suma de `area_m2` de todos los edificios.
`suitable_area_m2`	Double	Sí	Suma de `area_m2` de los edificios que cumplen el criterio de techo apto.
`params`	Object	Sí	Parámetros usados: `min_area_m2`, `min_confidence`, CRS del área.
`computed_at`	Date	Sí	Fecha y hora del cálculo.

Cuadro 6: Diccionario de datos de la colección `results` (métricas por municipio y fuente; se llena en la Entrega 4).

Campo	Tipo	Req.	Descripción
`_id`	ObjectId	Sí	Identificador del documento.
`dataset`	String	Sí	"mgn2025", "microsoft" o "google".
`file`	String	Sí	Archivo o URL de origen.
`rows_read`	Int64	Sí	Registros leídos.
`rows_inserted`	Int64	Sí	Registros insertados.
`rows_rejected`	Int64	Sí	Registros descartados (geometría irrecuperable o fuera de PDET).
`checksum`	String	Sí	SHA-256 del archivo de origen.
`loaded_at`	Date	Sí	Fecha y hora de la carga.

Cuadro 7: Diccionario de datos de la colección `ingestion_log` (bitácora de cargas: calidad y reproducibilidad).

Colección	Índice	Propósito
`municipalities`	`{ geometry: "2dsphere" }`	Consultas espaciales y asignación de municipio.
`municipalities`	`{ pdet_subregion: 1 }`	Agrupar y filtrar por subregión.
`buildings_microsoft`, `buildings_google`	`{ geometry: "2dsphere" }`	Consultas espaciales (`$geoWithin`, `$geoIntersects`).
`buildings_microsoft`, `buildings_google`	`{ municipality_code: 1, area_m2: 1 }`	Agregación por municipio y filtro por área.
`buildings_google`	`{ confidence: 1 }`	Filtro por umbral de confianza.
`results`	`{ municipality_code: 1, source: 1, computed_at: -1 }`	Última corrida por municipio y fuente.

Cuadro 8: Índices por colección.

```jsonc
// municipalities
{
  "_id": "05045",
  "name": "Apartadó",
  "department_code": "05",
  "department_name": "Antioquia",
  "pdet_subregion": "Urabá antioqueño",
  "area_km2": <double>,
  "geometry": { "type": "MultiPolygon", "coordinates": [ ... ] },
  "mgn_version": "MGN2025"
}
```

```jsonc
// buildings_google
{
  "geometry": { "type": "Polygon", "coordinates": [[[-76.63, 7.88], ... ]] },
  "area_m2": 85.3,
  "confidence": 0.87,
  "full_plus_code": "<plus code>",
  "municipality_code": "05045",
  "source_file": "<celda S2>.csv.gz",
  "is_valid_geom": true
}
```

5.2. Consultas de ejemplo

```javascript
// 1. Conteo y área por municipio con criterio de techo apto (Google)
db.buildings_google.aggregate([
  { $match: { confidence: { $gte: 0.70 }, area_m2: { $gte: 15 } } },
  { $group: { _id: "$municipality_code",
              n: { $sum: 1 }, area_m2: { $sum: "$area_m2" } } },
  { $sort: { area_m2: -1 } }
])

// 2. Validación cruzada: edificios dentro de un municipio (consulta espacial)
const m = db.municipalities.findOne({ _id: "05045" });
db.buildings_microsoft.countDocuments(
  { geometry: { $geoWithin: { $geometry: m.geometry } } })
```

Discusión de las decisiones clave.

- La consulta 1 agrupa por `municipality_code` sin ningún join espacial gracias a la pre-asignación hecha en el ETL; el `$match` aplica el criterio de techo apto, cuyos umbrales son parámetros.
- La consulta 2 usa `$geoWithin` con el polígono municipal para validar la pre-asignación. Los conteos pueden diferir ligeramente en los edificios que cruzan el límite municipal, porque la asignación usa el punto representativo y `$geoWithin` exige que el edificio completo quede dentro del polígono.

- En la Entrega 4 los resultados de la consulta 1 se materializan en `results` con `$merge`.

6. Conclusiones y Limitaciones

- El esquema separa las fuentes de los resultados, referencia los municipios por código DIVIPOLA y permite comparar Microsoft y Google sobre los mismos municipios PDET. MongoDB cubre las operaciones espaciales y las agregaciones que exige el proyecto.
- El criterio de techo apto es un supuesto metodológico: sus valores iniciales ($A_{\min} = 15$ m^2, $C_{\min} = 0.70$) se calibran en el EDA de la Entrega 3 y quedan guardados con cada resultado.
- Los nombres exactos de los campos del MGN y la cobertura de ambas fuentes sobre los 170 municipios PDET se verifican en las entregas 2 y 3; hasta entonces son supuestos del diseño.
- Los siguientes pasos son cargar las fronteras PDET con su índice `2dsphere` (Entrega 2) y cargar las huellas de edificios por lotes (Entrega 3).

El Cuadro 9 resume los riesgos identificados y su mitigación.

Riesgo	Mitigación
Volumen y tiempo de descarga o carga	Filtrado en origen, lotes, paralelismo y empezar la descarga desde la semana 1.
Geometrías inválidas rechazadas por `2dsphere`	`make_valid` en el ETL y registro en `ingestion_log`.
Municipios PDET mal identificados (versión del MGN o códigos)	Cruce por código DIVIPOLA de 5 dígitos y verificación de que el resultado sean 170 municipios.
Polígonos municipales muy detallados (límite de 16 MB por documento, rendimiento)	Verificar tamaño al cargar; si hace falta, usar una versión simplificada solo para visualización y conservar la original.
Duplicados o traslapes dentro de una fuente; fechas de captura distintas entre fuentes	Se reportan en el EDA; las fuentes no se fusionan, se comparan por municipio.
Carga de trabajo desigual en el equipo	Reparto por entregable y commits de ambos integrantes en cada entrega.

Cuadro 9: Riesgos y mitigaciones.

Referencias. Microsoft, *Microsoft Building Footprints* (Planetary Computer). Google Research, *Open Buildings*, versión 3. Technical University of Munich, *GlobalBuildingAtlas*. DANE, *Marco Geoestadístico Nacional (MGN) 2025*. Agencia de Renovación del Territorio, "¿Qué son los PDET?". Calderón Romero, A. O., enunciado del proyecto final de Administración de Bases de Datos (25 de octubre de 2026).